

나만의 주치의 — 전체 기능·개발 매뉴얼

medical-rag-service · 의료법 경계 안의 한국어 의료정보 RAG

기준일 2026-06-22 · 출시 전 검토용 프로토타입
웰니스 코칭 에이전트(기획 단계)는 범위 밖

목차

1. 개요
2. 시스템 아키텍처
3. 경계선 설계 (안전의 핵심)
4. 안전 불변식
5. RAG 생성 파이프라인
6. 개인화 — 해석 엔진 · 2경로 · 방향2 6게이트
7. 방향2 관찰성 (배지)
8. 멀티턴 문진
9. 뷰어 화면 (페르소나 테스트)
10. 개선 루프 (이벤트 스토어)
11. 성능
12. 데이터 · 마이그레이션
13. 운영 (배포 · 환경 변수)
14. 테스트
15. 출시 전 블로커

1. 개요

의료법(무면허 의료행위 27조) 경계 안에서 개인 건강 데이터를 활용하는 한국어 의료정보 RAG. 진단·처방 단정 0, 거절 대신 내비게이션(어디로 가야 하나)으로 욕구를 충족. B2B2C(건강관리 앱 임베드, GPT/Gemini와 경쟁). 파트너 대화 플랫폼(wraith)에 SSE로 연결.

핵심 설계 = 경계선 설계: 원시 측정값은 결정적 로컬 엔진이 해석해 중립 밴드 라벨로만 LLM·국외에 넘긴다.

2. 시스템 아키텍처



그림 1. 입력 → 개인화 해석(원시값 0) → 분류·검색·근거게이트 → 방향2 주입(옵트인) → LLM 생성 → 가드레일 후처리 → wraith SSE → 개선 루프.

개인화 결합은 2경로(둘 다 원시값 미투입): ① (기본) 결정적 중립 블록을 생성 후 답변에 후append, ② (방향2·옵트인) 비식별 밴드 라벨만 LLM system_prompt에 주입(6게이트 fail-closed, 기본 off).

3. 경계선 설계 (안전의 핵심)




그림 2. 원시 측정값은 결정적 해석 엔진에서 멈추고, 경계선 오른쪽으로는 밴드 라벨만 넘어간다.

위험의 축은 **개인 귀속 진단**이지 원시 수치 자체가 아니다. 따라서 ① 원시값(152/96)은 LLM 프롬프트에 절대 미투입(불변식 l1), ② 사용자에게도 중립 3단 라벨(안정/주의/경고)만 노출(l12), ③ 질환명 단정 0(l2).

4. 안전 불변식 (전 기능 공통)

ID	규칙	강제 위치
I1	원시 측정값을 표면화·LLM투입 안 함. 밴드 라벨·노트만.	vital_rules · 후append
I2	개인 귀속 진단 단정 0 (질환명 게이트)	personalization_safety C21
I7	응급 감지 시 개인화 결합 억제 (응급 안내 우선)	rag_engine · 방향2 G3
I8	임상 판독 금지 신호(ECG·웰니스 합성점수)는 밴드 조회 자체 안 함	vital_rules denied
I12	사용자 라벨은 중립 3단(안정/주의/경고)만. 질환 라벨은 내부 감사용.	vital_rules
게이트	질의 scope와 무관한 finding 미표면화 (과노출 차단)	relevance_gate
C20	주입 블록의 원시값·질환명 백스톱 스캔	scan_personal_block
C22	거짓안심("정상입니다") 백스톱 + 골든셋	find_false_reassurance
E2	분석 이벤트는 비식별(라벨·카운트·불리언)만	analytics_events.sanitize

5. RAG 생성 파이프라인

라이브 경로는 `rag_engine.generate_response` (스트리밍 제너레이터).

종료 4경로

경로	조건	동작
answer_shown	정상	생성 + 개인화 후append + 인용
insufficient_evidence	근거 부족	거절 → 내비게이션(어디로)
emergency_redirect	응급 분류	119·응급실, 개인화 억제(17)
triage_clarify	트리아지	되묻기

단계

- **분류·재작성**: `medical_classifier(intent·도메인)` + 멀티턴 후속 재작성(`followup_rewriter`, 응급이면 미재작성).
- **검색·근거 게이트**: `hybrid_search(BM25+벡터, top_k=5)` → `retrieval_router`가 top1점수·관련청크·토픽으로 SUFFICIENT/WEAK/INSUFFICIENT 판정.
- **가드레일 후처리**: `ComplianceAnalyzer` 재분석 → CRITICAL 차단 / HIGH 1회 재생성 / 오탐 필터. 면책 상·하 단 자동 부착.
- **인용**: 본문 [n]→청크 매핑. `citation_verifier·grounding`은 shadow(로그·검수 신호, 답변 무변경).

6. 개인화 — 해석 엔진 · 2경로 · 방향2 6게이트

해석 엔진 4축 (원시값 노출 0)

축	모듈	산출
밴드	vital_rules.run / lookup_band	혈압·산소·체온·심박·BMI → 안정/주의/경고
추세	run_trends / label_trend	지속상승/저하/불안정 (건강판단 금지)
환경	env_rules.air_quality_finding	나쁨→주의/매우나쁨→경고, 환기 권유
교차	match_cross_signals	I9 화이트리스트(혈압+BMI 대사묵음)

방향2 — 비식별 밴드 라벨 LLM 주입 (6게이트 fail-closed)




그림 3. G1~G6 모두 통과해야 주입. 하나라도 미충족이면 미주입(fail-closed). 들어가는 것은 중립 밴드 라벨뿐 — 원시값·진단명 0.

7. 방향2 관찰성 (배지)

주입이 실제 일어났는지 답변만으론 알기 어렵다 → 주입된 밴드를 `STOP.personal_injected` 로 내려보내 뷰어가  **배지**로 표시. 미주입이면 빈 리스트(음성 확인). A/B 실측: ON이면 경고 밴드를 반영해 "  서둘러 진료" 섹션이 추가되고, OFF엔 없음.

8. 멀티턴 문진

간단히 물으면 **답변을 먼저** 주고, 그 답변을 바탕으로 **한 번에 한 질문씩** 선택지를 제시(Claude Code 인풋 방식). 모든 선택이 모이면 "원질의 / 문진: ..."로 정밀 재안내. followups.clarify가 토픽별 질문+선택지를 생성, 뷰어가 버튼으로 렌더.

9. 뷰어 화면 (페르소나 테스트)

localhost:8770 · 3분할 반응형. ① 페르소나 선택 ② 개인화 정보(밴드·결합블록·LLM 맥락·차트·처방) ③ 대화(답변·인용·개인맥락 배지·문진 버튼).

① 페르소나

고혈압 어르신

65세 · 고혈압

혈압 경고

다른 페르소나

당뇨 직장인

임신부

천식 아동

② 개인화 정보

혈압 경고 심박 안정 추세 상승

결합 블록

최근 혈압이 '경고' 구간이에요. 재측정하고 지속되면 진료를 권합니다.

LLM 비식별 맥락 (방향2)

혈압=경고 (밴드 라벨만)

혈압 추이 (14일)

③ 대화

혈압이 높게 나왔어요

일시적으로 높을 수 있어 다시 측정해 확인하세요 1. 두통·가슴통증이 함께면 바로 진료가 필요합니다 2.

🔒 개인맥락 반영됨 — 혈압=경고

(1/3) 증상이 시작된 지 얼마나 됐나요?

오늘

2~3일

일주일+

괜찮아요

그림 4. 페르소나 테스트 뷰어 3분할 화면 구성(고혈압 어르신 · 혈압 경고 예시).

10. 개선 루프 (이벤트 스토어)




그림 5. 진입·종료 4종·피드백 이벤트가 비식별 이벤트 스토어로 모여 BI·품질·개선으로 흐른다.

허브 = 이벤트 스토어(Postgres, analytics_events). emit()은 화이트리스트 sanitize(라벨·카운트·불리언만, 금지키 구조적 제거). BI=Metabase/Grafana, 품질=골든셋·judge. PostHog는 선택. rag_queries는 원문 보관(내부 감사용, BI 미사용).

11. 성능 (2026-06-22)

체감 응답 ~40초 → ~8초(warm). 진범은 LLM/검색이 아니라 SSE 연결을 30초 늦게 닫던 keep-alive였다.

측정	이전	지금(warm)
Cloud Run 요청 레이턴시	~40초	~7.7초
첫 토큰 전 추론(프리필)	12.75초	~1초
꼬리(마지막 토큰→STOP)	~30초	~0초

- SSE 연결 즉시 종료: `Connection: close` + `close_connection` (keep-alive+setTimeout(30) 유힬 대기 제거).
- `reasoning_effort=minimal`: gpt-5.4-mini 지원값 minimal/low/medium/high (none은 400, fail-safe).
- DB 후처리 비차단화: 감사·검수·analytics 데몬 스레드.
- INSUFFICIENT 인용-0건 재생성 생략.

12. 데이터 · 마이그레이션 (PG + _sqlite)

#	테이블·변경
001	kb_sources·kb_documents·kb_chunks·llm_providers·rag_queries
005	evidence_grounding(근거 게이트 컬럼)
010	vital_reference_ranges
011	conversations 호환 컬럼
013	rag_queries 멀티턴 감사 컬럼
014	rag_projects
015	analytics_events(비식별 이벤트)
016	response_feedback(명시 피드백)

012 미사용(예약). SQLite 러너는 ; split → 주석에 세미콜론 금지. 영속 개인화(personal_record 등)는 017+ 예약.
방향2는 마이그레이션 없음(env 플래그).

13. 운영 (배포 · 환경 변수)

배포: `deploy-rag.ps1` → Cloud Run `medical-rag-dev` (asia-northeast3). `RUN_MODE=rag`, `gpt-5.4-mini`, `LLM_REASONING_EFFORT=minimal`(영속).

개인화 플래그 리셋 주의: `PERSONAL_SIGNAL_TO_LLM·ALLOW_CROSS_BORDER_PERSONAL`는 컴플라이언스상 deploy 스크립트에 미포함(기본 `off=fail-closed`). `--set-env-vars` 전체교체 재배포마다 `off`로 리셋 → 시연 시 매 배포 후 `gcloud run services update ... --update-env-vars` 로 재적용.

14. 테스트 · 출시 전 블로커

`python -m pytest tests/ -q` — 664개 수집. 순수 함수·결정적 위주. 골든셋: 멀티턴 게이트($\geq 80\%$), 거짓안심 0(C22), 페르소나 E2E.

- **출시 차단** — A 의료법 27조 변호사 검토(밴드 라벨=개인 의학 평가가 의료행위로 해석될 리스크) · B 민감정보+국외이전 실제 동의 시스템(현재 게이트만) · D KB 의료진 검수.
- C 국내 LLM 경로 · E 영속·암호화 · G 운영등급 배포.

정직 포인트: 개인화를 하는 순간(방향2 off여도 후append 포함) 의료법 질문은 존재. "원시값 미투입"은 LLM 한정이고 원문은 rag_queries에 저장. "기본 off=안전"이 아니라 "그 기능 미사용"일 뿐. 페르소나=합성 데이터, KB=dev. **테스트 그린 ≠ 출시 가능.**